

基于改进 GhostNet 模型的表情识别研究

张文海, 陈春玲

(南京邮电大学 计算机学院、软件学院、网络空间安全学院, 江苏 南京 210023)

摘要:针对目前卷积神经网络应用到人脸表情识别任务上时,计算复杂、输入尺度过大、类间差异小和类内差异大等问题,提出了一种基于改进 GhostNet 模型的解决方法。首先,结合 GhostNet 模型思想,设计了改进 GhostNet 模型来提取表情特征,比原网络模型拥有更好的轻量级特性,并解决了 Ghost 瓶颈层中可能导致信息丢失的问题。其次,结合 Island 损失函数和 Circle 损失函数设计思想,设计并采用了基于余弦相似性的损失函数来指导神经网络的学习。该方法可以在特征空间中减小类内差异,增大类间差异,从而提升特征判别能力。在 FERplus 数据集上进行实验验证,基于改进 GhostNet 模型方法在模型参数数量和计算量更少的前提下,依旧有着更高的识别准确率和更快的识别速度,效果优于 Softmax 交叉熵损失函数和基于余弦距离的损失函数等,更适合移动端和嵌入式设备的使用场景。

关键词:表情识别;损失函数;深度学习;卷积神经网络;GhostNet

中图分类号:TP391.4

文献标识码:A

文章编号:1673-629X(2022)08-0060-06

doi:10.3969/j.issn.1673-629X.2022.08.010

Research on Expression Recognition Based on Modified GhostNet Model

ZHANG Wen-hai, CHEN Chun-ling

(School of Computer Science, Computer Science, Nanjing University of Posts and Telecommunications, Nanjing 210023, China)

Abstract: To solve the problems of the complex calculations, the large input scale, the small difference in between-class expressions and the large difference in within-class expressions in facial expression recognition task, a solution based on modified GhostNet model is proposed. Firstly, a modified GhostNet model is designed to extract expression features based on the idea of GhostNet model, which has better lightweight characteristics than the original network model, and the problem that the information may be lost in the Ghost bottleneck layer is solved. Secondly, combined with the idea of Island loss function and Circle loss function, the loss function based on cosine similarity is designed and used to guide the learning of neural network. The method reduces the intra class difference and increases the inter class difference in the feature space, thereby improving the effect of feature discrimination. Experiments on FERplus data set show that the proposed method based on improved GhostNet model has higher recognition accuracy and faster recognition speed on the premise of the fewer parameters and calculations. The effect is better than Softmax and the loss function based on cosine similarity. It is more suitable for use scenarios of mobile terminals and embedded devices.

Key words: expression recognition; loss function; deep learning; convolutional neural network; GhostNet

0 引言

通过深度学习方法提取表情特征信息是目前最广泛使用且有效的方法^[1],但随着深度神经网络模型不断发展,网络模型越来越复杂,参数和计算量不断变大,导致模型的使用只能在特定的应用场合,很难应用到移动设备和嵌入式设备上。为解决这个问题,Howard 等于 2017 年提出 MobileNet^[2] 模型,通过将一个标准卷积拆分成逐通道卷积和逐点卷积的方法大幅

减少了计算量;Sandler 等提出倒残差模块和线性瓶颈层,并以此设计了 MobileNet V2 模型^[3];2019 年,Howard 等提出 MobileNet V3 模型^[4],在倒残差模块中引入了 SE 注意力机制,并修改 MobileNet V2 中计算量偏大的开头和结尾两层,该模型在分类和检测等任务上准确率和速度都优于前几版;2020 年,针对生成的特征图中存在大量的冗余信息,Han 等提出 GhostNet 模型^[5],使用恒等映射的方式直接生成这些

收稿日期:2021-09-16

修回日期:2022-01-18

基金项目:国家重点研发计划(2018YFC1314900);江苏省高校自然科学基金计划(18KJB520038)

作者简介:张文海(1995-),男,硕士,研究方向为图像识别;陈春玲,教授,研究方向为软件工程、分布式组件技术、网络信息安全及其应用。

冗余的特征图,大幅减少了参数量和计算量。但这些模型当中,即便是最小的图像输入分辨率也是 96×96 ,而人脸表情识别任务则可以使用更低的分辨率。

目前卷积神经网络大都采用 Softmax 交叉熵损失函数来优化类间的特征差异,并未考虑到人脸表情信息中类内的特征差异。为解决这个问题,Wen 等提出中心损失函数^[6],使样本均匀分布于类中心周围,减小类内差异;Cai 等在中心损失函数的基础上提出 Island 损失函数^[7],优化类中心的位置,增大类间差异。事实上,基于 Softmax 交叉熵损失函数改进得到的各种损失函数都是在做减小类间相似性、增大类内相似性的工作。但是这样的优化方式将正负样本都以相同方式优化,不够灵活,于是 Sun 等提出 Circle 损失函数^[8],引入相似性权重因子,对类内相似性和类间相似性给予不同的惩罚强度,从而使优化更加灵活。

基于上述内容,该文主要工作有以下两点:

(1)针对现有的轻量级神经网络的缺点和表情数据的特点,提出一个输入图像分辨率为 48×48 的改进 GhostNet 模型——M-GhostNet。该模型不仅大幅减少了参数和计算量,并且更加符合人脸表情识别任务的特点,更加符合移动端和嵌入式设备的使用场景。在 FERplus 数据集^[9]上取得了较高的识别准确率和识别速度。

(2)针对 Softmax 交叉熵损失函数不能压缩类内空间,优化不灵活等问题,结合 Circle 损失函数和 Island 损失函数,提出基于余弦相似性的损失函数,在 FERplus 数据集上获得了不错的效果。

1 改进的 GhostNet 网络模型

1.1 Ghost 模块

文献[5]对 ResNet50 的某层输出进行可视化分析,发现训练过程中的特征图中存在着大量重复、冗余的特征图。因此可以定义其中一张特征图为本征图,与其相似的特征图则可以被定义为 Ghost 图。既然 Ghost 图与本征图相似,那么就不需要使用占用内存多,计算复杂等高成本的卷积操作,直接使用低成本的线性变换或者其他廉价的操作得到。

图1(a)是常规卷积操作,图1(b)是 Ghost 模块的具体操作。可以看出 Ghost 模块主要由三部分组成:第一步,将输入图像通过常规卷积得到本征图;第二步,对本征图做线性变换或其他廉价操作生成 Ghost 图;第三步,将本征图与 Ghost 图拼接作为输出。假设每张本征图都存在着与之对应的 s 张 Ghost 图,这 s 张 Ghost 图仅需通过线性变换方式获得,那么从整体上来看,Ghost 模块相较于常规卷积操作会减少大约 s 倍的参数量和计算量。




图1 常规卷积和 Ghost 模块

1.2 改进的 GhostNet 模型

ReLU 激活函数凭借着其低计算复杂度和快速的收敛效果,成为大部分卷积神经网络模型首选的激活函数,GhostNet 也不例外。但是其函数曲线不平滑,并且在模型训练的时候,容易导致部分神经元“坏死”。所以在改进的 GhostNet 中摒弃了 ReLU 函数,改用函数曲线更为平滑,可以保留部分负值信息的 Mish 函数^[10]。Mish 函数表达式为:

$$\text{Mish}(x) = x \cdot \tanh(\ln(1 + e^x)) \quad (1)$$

Mish 函数性质同 ReLU 函数一样无上界,有下界,但是 Mish 函数保留了少量的负值信息,避免了 ReLU 函数可能产生的 Dying ReLU 现象,即部分神经元在反向传播时可能不起作用的现象^[11]。并且 Mish 函数更为平滑,这样随着网络的深度增加,样本的信息也能传递到更深的网络层中,整个模型更加容易优化,最终的模型也能有更好的泛化效果。

参照 ResNet 中的残差结构^[12],使用 Ghost 模块,可以堆叠出 Ghost 瓶颈层。使用 Mish 函数作为新的激活函数的改进 Ghost 瓶颈层结构如图2所示。




图2 改进 Ghost 瓶颈层

结合人脸表情数据的特性,在保持高准确率的前提下,尽可能地减少网络模型的参数量和计算量,该文设计出一个基于改进 Ghost 瓶颈层,输入尺寸为 $48 \times 48 \times 3$,适用于七分类表情识别任务的改进 GhostNet 网络模型 M-GhostNet,其详细网络结构如表1所示。

表 1 M-GhostNet 网络结构

Operator	Input	#exp	#out	SE	Stride
常规卷积层	48×48×3	—	16	—	2
Ghost 瓶颈层	24×24×16	16	16	1	1
Ghost 瓶颈层	24×24×16	72	24	—	1
Ghost 瓶颈层	24×24×24	88	24	—	2
Ghost 瓶颈层	12×12×24	96	40	1	1
Ghost 瓶颈层	12×12×40	200	40	1	1
Ghost 瓶颈层	12×12×40	240	40	1	1
Ghost 瓶颈层	12×12×40	288	48	1	1
Ghost 瓶颈层	12×12×48	288	48	1	1
Ghost 瓶颈层	12×12×48	488	96	1	2
Ghost 瓶颈层	6×6×96	576	96	1	1
Ghost 瓶颈层	6×6×96	576	96	1	1
逐点卷积层	6×6×96	—	96	—	1
平均池化层	6×6×96	—	—	—	—
逐点卷积层	1×1×96	—	96	—	1
全连接层	1×1×7	—	7	—	—

其中#exp 表示改进 Ghost 瓶颈层中经过第一个 Ghost 模块处理过后的通道数,#out 表示该层输出的通道数,SE 为 1 表示该层使用了注意力机制,Stride 表示步长。采用 Mish 函数作为每层的激活函数。

经过理论和实验验证,M-GhostNet 的参数数量和计算量比 MobileNet V2、MobileNet V3 和 GhostNet 有着大幅的降低,并且在表情识别任务上保持着较高的准确率。具体参数数量和计算量的对比见表 2。

表 2 模型参数量、FLOPs 对比

模型	参数量	FLOPs/G
M-GhostNet	303,129	0.714
MobileNet V2	2,266,951	9.8
MobileNet V3	1,537,143	1.87
GhostNet	2,598,088	6.89

可以看出,M-GhostNet 的参数数量比 MobileNet V2 和 GhostNet 减少 90% 左右,比 Mobile V3 减少 80% 左右。浮点运算量比 MobileNet V3 少了 62% 左右,比 GhostNet 少了 90% 左右,比 MobileNet V2 更是少了 93% 左右。

2 基于余弦相似性的损失函数

2.1 Softmax 交叉熵损失函数

Softmax 交叉熵损失函数是卷积神经网络常用的损失函数。在一个拥有 N 个嵌入式表示实例集合的分类任务中, x_i 是神经网络全连接层输出的第 i 个样本的特征向量, w_j 、 b_j 是第 j 类对应的全连接层的权重

和偏置。Softmax 交叉熵损失函数的计算公式为:

$$L_s = - \sum_{i=1}^N \ln \frac{\exp(w_i x_i + b_i)}{\sum_{j=1}^N \exp(w_j x_j + b_j)} \quad (2)$$

2.2 Island 损失函数

Island 损失函数是基于中心损失函数改进得来的,中心损失函数的计算公式为:

$$L_c = L_s + \frac{\lambda}{2} \sum_{i=1}^N \|x_i - c_i\|^2 \quad (3)$$

其中, c_i 是第 i 类的中心, λ 用于调节两项的比例。但是由于中心损失函数只考虑到了样本向其类中心分布,缩小了类内的差异,没有考虑类间的差异,故 Island 损失函数在式(5)的基础上优化了类中心之间的欧氏距离,计算公式为:

$$L_l = L_s + \lambda \left[\frac{1}{2} \sum_{i=1}^N \|x_i - c_i\|^2 + \lambda_1 \sum_{c_j \in N} \sum_{\substack{c_k \in N \\ c_j \neq c_k}} \left(\frac{c_j c_k}{\|c_j\| \|c_k\|} + 1 \right) \right] \quad (4)$$

其中, λ_1 超参数用于调节新增项和中心损失函数的比例。式(4)中的尾项惩罚了类与类之间的相似性,从而增大了类间距离。

2.3 基于余弦相似性的 Island 损失函数

虽然 Island 损失函数可以很好地增加类间距离,缩小类内距离,但由于 Softmax 交叉熵损失函数本身并不能减少类内差异性,所以 Island 损失函数的性能依旧受限于 Softmax 交叉熵损失函数,影响最终分类的准确率。大部分以 Softmax 交叉熵损失函数为基础

的一系列改进的损失函数,比如:Triplet 损失函数^[13]、AM-Softmax 损失函数^[14]等,本质上都是在最大化类内相似度 s_p ,最小化类间相似度 s_n ,即优化式(5):

$$\min(s_n - s_p) \quad (5)$$

如果直接优化 $s_n - s_p$,那么网络模型最终将收敛并得到这样一个决策边界:

$$s_n - s_p = \text{margin} \quad (6)$$

这些损失函数在优化的时候会对 s_n 、 s_p 做相同力度的惩罚。比如,当 s_n 已经是一个十分小的值,但 s_p 却是一个相对较大的值时,虽然此时模型已经可以很好地聚合相同的类,但由于 s_p 是个较大值,需要受到一个较大的惩罚力度,而 s_n 却因此也需要受到相同的惩罚力度,这显然是不合适的。

鉴于该问题,引入两个独立的非负权重参数 α_n 、 α_p ,分别控制 s_n 、 s_p 以不同的速率进行优化。又因为 s_n 、 s_p 分开进行优化,边界值 margin 不再是它们共同的边界值,所以需要为它们引入两个不同的边界值,类间边界值 Δ_n 和类内边界值 Δ_p ,则新的决策边界为:

$$\alpha_n(s_n - \Delta_n) - \alpha_p(s_p - \Delta_p) = 0 \quad (7)$$

假设给定的特征空间中有单个样本 x ,与其相关的有 K 个类内相似度分数, L 个类间相似度分数,那么类内相似度分数可以定义为 $\{s_p^i\} (i = 1, 2, \dots, K)$,类间相似度分数定义为 $\{s_n^i\} (i = 1, 2, \dots, L)$,则可以得出 Circle 损失函数为:

$$L_{\text{circle}} = \ln[1 + \sum_{j=1}^L \exp(\gamma \alpha_n^j (s_n^j - \Delta_n)) \sum_{i=1}^K \exp(-\gamma \alpha_p^i (s_p^i - \Delta_p))] \quad (8)$$

其中, γ 是缩放因子。假设最优的 s_p^i 值为 O_p ,最优的 s_n^j 值为 O_n ,为了满足相似度与最优值差距过大时,可以有较大的权重去惩罚,引入的两个独立的权重参数可以表示为:

$$\begin{cases} \alpha_n^j = [s_n^j - O_n]_+ \\ \alpha_p^i = [O_p - s_p^i]_+ \end{cases} \quad (9)$$

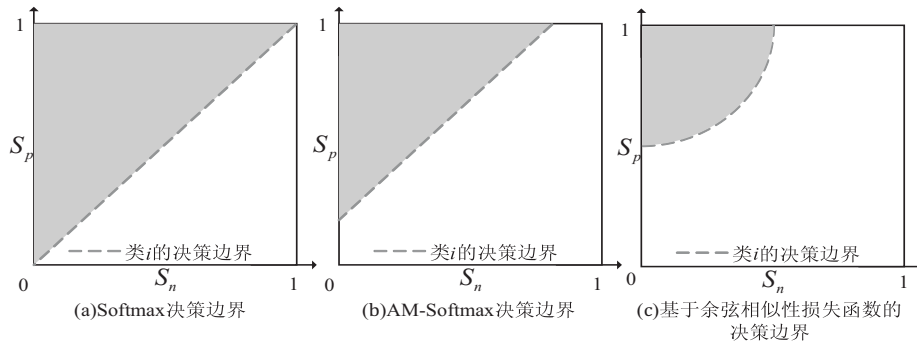


图 3 Softmax、AM-Softmax 和基于余弦相似性损失函数的决策边界

如图 3(a) 所示,Softmax 交叉熵损失函数的决策边距为 0,并不能更好地分类与类,减少类内的差异性。图 3(b) 中 AM-Softmax 损失函数引入了余弦距

其中, $[\cdot]_+$ 表示取非负数操作。将式(7)与式(9)结合,可以得到新的决策边界:

$$\left(s_n - \frac{O_n + \Delta_n}{2}\right)^2 + \left(s_p - \frac{O_p + \Delta_p}{2}\right)^2 = \frac{(O_n - \Delta_n)^2 + (O_p - \Delta_p)^2}{4} \quad (10)$$

为了简化参数,可以设 $O_p = 1 + m$, $O_n = -m$, $\Delta_p = 1 - m$, $\Delta_n = m$,这样新的决策边界就变成:

$$s_n^2 + (s_p - 1)^2 = 2m^2 \quad (11)$$

综上,最终的 Circle 损失函数可以表示为:

$$L_{\text{circle}} = \ln[1 + \sum_{j=1}^L \exp(\gamma [s_n^j + m]_+ (s_n^j - m)) \sum_{i=1}^K \exp(-\gamma [1 + m - s_p^i]_+ (s_p^i - 1 + m))] \quad (12)$$

该文提出的基于余弦相似性的损失函数的中心思想就是使用 Circle 损失函数替换 Island 损失函数中的 Softmax 函数,新的计算公式可以表示为:

$$L_{\text{newloss}} = \ln[1 + \sum_{j=1}^L \exp(\gamma [s_n^j + m]_+ (s_n^j - m)) \sum_{i=1}^K \exp(-\gamma [1 + m - s_p^i]_+ (s_p^i - 1 + m))] + \lambda \left[\frac{1}{2} \sum_{i=1}^N \|x_i - c_i\|^2 + \lambda_1 \sum_{c_j \in N} \sum_{c_k \in N, c_j \neq c_k} \left(\frac{c_j c_k}{\|c_j\| \|c_k\|} + 1 \right) \right] \quad (13)$$

新的损失函数不仅弥补了 Softmax 交叉熵损失函数无法更好地聚合同类样本的缺陷,而且可以让各类样本更加灵活地朝着更加合适方向收敛。同时,第二项可以约束每个样本分布在其类中心周围,缓解类内差异,增大类间差异。

图 3 是 Softmax 交叉熵损失函数、AM-Softmax 损失函数和基于余弦相似性的损失函数在某一分类任务中类 x_i 的决策边界。

离 margin ,可以更好区分类,并压缩类内空间。图 3(c) 中基于余弦相似性的损失函数的决策边距则与超参数 m 相关,由式(12)可以得出,当 $m \leq 0.5$ 时,两个

类之间就不会相交,当 m 越来越小时,两个类的决策边距也就越来越大,从而更好地放大类间距离,压缩类内空间。由于图 3(c) 是圆形边界,样本在收敛过程会比图 3(b) 拥有更明确的收敛方向。实验中 m 取值 0.35,缩放因子 γ 取值 2,Island 损失函数的超参数 λ 、 λ_1 分别设置为 0.01 和 10。

特别地,当 $K=1$ 时,即样本中只有一个正样本,其余均为负样本,基于余弦相似性的 Island 损失函数就退化成了文献[15]中的基于余弦距离的损失函数。

3 实验

3.1 实验环境与设置

实验以 TensorFlow 2.4 框架为基础,编程语言为 Python 3.7。实验训练都在 GPU 上进行,GPU 的型号为 Nvidia GeForce RTX 2060,6 GB 显存。实验中采取 SGD 优化器,动量为 0.9,学习率初始设置为 0.01,随着训练轮数的增加,通过余弦退火策略降低学习率^[16]。实验模型在数据集上训练 100 轮。批大小为 16。对输入的图片在归一化的前提下,进行随机旋转 30 度、上下左右移动、缩放和剪切等数据增强手段处理^[17]。

该文所涉及的方法分别在 FERplus 数据集上进行七分类对比实验。FERplus 数据集是针对 FER2013 数据集中数据标注错误和冗余等问题而重新标注的数据集^[18]。原数据集总共有十类表情,而实验选取七类,去除掉“轻蔑”、“未知”和“非人脸”三个标签,总共 35 493 张图片。然后按照 8:1:1 的比例将数据随机拆分为训练集、验证集和测试集。训练好的模型用测试集来测试识别准确率。

3.2 实验结果与分析

文中模型与其他算法模型在 FERplus 数据集上的对比实验结果如表 3 所示,损失函数为 Softmax, \times 表示模型的缩放因子,每个模型的缩放因子设置参考了文献[5]的分类实验设置。

表 3 各模型在 FERplus 数据集上的准确率

模型	准确率/%
GhostNet 0.5 \times	78.251
MobileNet V2 0.35 \times	71.711
MobileNet V3 Small 0.75 \times	78.725
M-GhostNet	79.339

从表 3 可以看出,使用了 Mish 激活函数替换 ReLU 激活函数的 M-GhostNet,在参数和计算量均少于 GhostNet、MobileNet V2 和 MobileNet V3 的前提下,依旧保持了较高的准确率,比 GhostNet 高了 1.008%,比 MobileNet V2 高了 7.628%,比 MobileNet V3 高了

0.614%,可以看出选用 Mish 函数能够在表情分类任务中提高识别准确率。

为了控制变量,损失函数的对比实验均使用 M-GhostNet 模型,在 FERplus 数据集上进行。其中 AM-Softmax 的超参数 margin 设置为 0.35。

从表 4 可以看出,基于余弦相似度的损失函数比传统的 Softmax 交叉熵损失函数准确率高了 3.222%,比 Island 损失函数高了 2.431%,比 AM-Softmax 损失函数高了 2.177%,比 Circle 损失函数高了 0.904%,比基于余弦距离的损失函数高了 0.512%。实验结果表明基于余弦相似性的损失函数可以学习到更具有区分力度的表情特征,更好地地区分类,提高表情识别任务的准确率。

表 4 各损失函数在 FERplus 数据集上的准确率

损失函数	准确率/%
Softmax	79.339
Island Loss ^[6]	80.130
AM-Softmax ^[13]	80.384
Circle Loss ^[8]	81.657
基于余弦距离的损失函数 ^[16]	82.049
基于余弦相似度的损失函数	82.561

表 5 是各模型预测一张图片所需时间对比,模型均运行在 CPU 上,CPU 型号为 Intel Core i7-9750H 2.60 GHz。可以看出改进 GhostNet 模型预测所需时间更少,从而可以得出预测速度更快,实时性更好。

表 5 各模型预测所需时间对比

模型	时间/ms
GhostNet 0.5 \times	54.873
MobileNet V2 0.35 \times	70.283
MobileNet V3 Small 0.75 \times	32.912
M-GhostNet	30.882

4 结束语

该文设计了一种基于改进的 GhostNet 神经网络模型,用于人脸表情的特征提取和分类任务。该模型不仅拥有轻量级网络的参数少、计算复杂度低、训练快等特性,还解决了 ReLU 函数可能导致的信息丢失的问题,保持了较高的识别准确率。同时,针对表情数据的特性,提出了基于余弦相似度的损失函数,可以更好地增加类间差异,减小类内差异,提高模型的识别准确率。实验结果表明,改进 GhostNet 模型和基于余弦相似性的损失函数可以在人脸表情识别任务上有着较高的识别准确率和速度优势。下面将继续研究表情样本分布不均的问题,提高模型的准确率,实现表情识别的自动化和智能化。

参考文献:

- [1] 薛继伟,吕福娟,刘显德. 基于改进 ResNet 的人脸表情识别研究[J]. 河南科学,2021,39(8):1205-1210.
- [2] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: efficient convolutional neural networks for mobile vision applications[EB/OL]. (2017-04-14) [2019-06-23]. <https://arxiv.org/abs/1704.04861>.
- [3] SANDLER M, HOWARD A, ZHU M, et al. MobileNetV2: inverted residuals and linear bottlenecks[EB/OL]. (2019-03-21) [2021-09-01]. <https://arxiv.org/abs/1801.04381>.
- [4] HOWARD A, SANDLER M, CHEN B, et al. Searching for MobileNetV3 [C]//2019 IEEE/CVF international conference on computer vision (ICCV). Seoul, Korea (South): IEEE, 2020:1314-1324.
- [5] HAN K, WANG Y, TIAN Q, et al. GhostNet: more features from cheap operations[C]//2020 IEEE/CVF conference on computer vision and pattern recognition (CVPR). Seattle, WA, USA: IEEE, 2020:1577-1586.
- [6] WEN Y, ZHANG K, LI Z, et al. A discriminative feature learning approach for deep face recognition[C]//Proceedings of European conference on computer vision. Amsterdam: Springer, 2016:499-515.
- [7] CAI J, MENG Z, KHAN A S, et al. Island loss for learning discriminative features in facial expression recognition[C]//Proceedings of 2018 13th IEEE international conference on automatic face & gesture recognition (FG 2018). Xi'an, China: IEEE, 2018:302-309.
- [8] SUN Y, CHENG C, ZHANG Y, et al. Circle loss: a unified perspective of pair similarity optimization[C]//2020 IEEE/CVF conference on computer vision and pattern recognition (CVPR). Seattle, WA, USA: IEEE, 2020:6397-6406.
- [9] BARSOUM E, ZHANG C, FERRER C C, et al. Training deep networks for facial expression recognition with crowd-sourced label distribution [C]//Proceedings of the 18th ACM international conference on multimodal interaction. Tokyo: ICMI, 2016:279-283.
- [10] MISRA D. Mish: a self regularized non-monotonic neural activation function[J]. arXiv:1908.08681, 2019.
- [11] 高淑萍,赵清源,齐小刚,等. 改进 MobileNet 的图像分类方法研究[J]. 智能系统学报, 2021, 16(1):11-20.
- [12] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Las Vegas, USA: IEEE, 2016:770-778.
- [13] SCHROFF F, KALENICHENKO D, PHILBIN J. Facenet: a unified embedding for face recognition and clustering[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Boston, MA, USA: IEEE, 2015: 815-823.
- [14] WANG F, LIU W, LIU H, et al. Additive margin softmax for face verification[J]. IEEE Signal Processing Letters, 2018, 25(7):926-930.
- [15] 吴慧华,苏寒松,刘高华,等. 基于余弦距离损失函数的人脸表情识别算法[J]. 激光与光电子学进展, 2019, 56(24): 188-194.
- [16] LOSHCHILOV I, HUTTER F. SGDR: stochastic gradient descent with warm restarts[J]. arXiv:1608.03983, 2016.
- [17] 张翔,史志才,陈良. 引入注意力机制和中心损失的表情识别算法[J]. 传感器与微系统, 2020, 39(11): 148-151.
- [18] 彭小江,乔宇. 面部表情分析进展和挑战[J]. 中国图象图形学报, 2020, 25(11):2337-2348.
- (上接第59页)
- ture learning on point sets in a metric space[C]//Advances in neural information processing systems. Long Beach: ACM, 2017:5099-5108.
- [11] WEI Y, XIA W, LIN M, et al. HCP: a flexible CNN framework for multi-label image classification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(9):1901-1907.
- [12] CARSTEN M, DODGSON N A. Fast marching farthest point sampling[R]. Cambridge: University of Cambridge, 2003.
- [13] 张彤,秦小麟. 时间依赖路网上的移动对象 K 近邻查询算法[J]. 计算机科学, 2020, 47(1):79-86.
- [14] 孙红,凌岳览. 融合 MKF 的 Pointnet++ 优化算法研究[J]. 小型微型计算机系统, 2020, 41(6):1269-1273.
- [15] CHEN Y, LIU G L, XU Y, et al. PointNet++ network architecture with individual point level and global features on Centroid for ALS point cloud classification[J]. Remote Sensing, 2021, 13(3):472.
- [16] XIE Yuxing, TIAN Jiaojiao, ZHU Xiaoxiang. Linking points with labels in 3D: a review of point cloud semantic segmentation[J]. IEEE Geoscience and Remote Sensing Magazine, 2020, 8(4):38-59.
- [17] SIEGEL J. The importance of loss functions: a note on the evolution of the toxicity probability interval design[J]. Contemporary Clinical Trials Communications, 2021, 22(9): 100694.
- [18] CHANG A X, FUNKHOUSER T, GUIBAS L, et al. Shapenet: an information-rich 3d model repository[J]. arXiv: 1512.03012, 2015.
- [19] ZHANG Youshan, DAVISON B D. Shapenet: age-focused landmark shape prediction with regressive CNN[C]//2019 international conference on content-based multimedia indexing (CBMI). Dublin: IEEE, 2019.