

学 号： 2020212605

密 级： 公开

合肥工业大学

Hefei University of Technology

# 本科毕业设计（论文）

UNDERGRADUATE THESIS



类 型： 设计

题 目： 基于无监督学习的偏振图像去雾算法设计与实现

专业名称： 通信工程

入校年份： 2020 级

学生姓名： 项泉智

指导教师： 王昕 副教授

学院名称： 计算机与信息学院

完成时间： 2024 年 5 月

---

合 肥 工 业 大 学

本科毕业设计（论文）

基于无监督学习的  
偏振图像去雾算法设计与实现

学生姓名：项泉智

学生学号：2020212605

指导教师：王昕 副教授

专业名称：通信工程

学院名称：计算机与信息学院

2024 年 5 月

---

**A Dissertation Submitted for the Degree of Bachelor**

**Design and Implementation of  
a Polarimetric Image Dehazing Method  
Based on Unsupervised Learning**

By

Xiang Quanzhi

Hefei University of Technology

Hefei, Anhui, P.R.China

May, 2024

## 毕业设计（论文）独创性声明

本人郑重声明：所呈交的毕业设计（论文）是本人在指导教师指导下进行独立研究工作所取得的成果。据我所知，除了文中特别加以标注和致谢的内容外，设计（论文）中不包含其他人已经发表或撰写过的研究成果，也不包含为获得合肥工业大学或其他教育机构的学位或证书而使用过的材料。对本文成果做出贡献的个人和集体，本人已在设计（论文）中作了明确的说明，并表示谢意。

毕业设计（论文）中表达的观点纯属作者本人观点，与合肥工业大学无关。

毕业设计（论文）作者签名：项泉智 签名日期：2024 年 5 月 15 日

## 毕业设计（论文）版权使用授权书

本学位论文作者完全了解合肥工业大学有关保留、使用毕业设计（论文）的规定，即：除保密期内的涉密设计（论文）外，学校有权保存并向国家有关部门或机构送交设计（论文）的复印件和电子光盘，允许设计（论文）被查阅或借阅。本人授权合肥工业大学可以将本毕业设计（论文）的全部或部分内  
容编入有关数据库，允许采用影印、缩印或扫描等复制手段保存、汇编毕业设计（论文）。

（保密的毕业设计（论文）在解密后适用本授权书）

学位论文作者签名：项泉智

指导教师签名：王昕

签名日期：2024 年 5 月 15 日

签名日期：2024 年 5 月 15 日

---

## 摘要

雾霾是一种常见的大气自然现象。偏振可以提供与光谱和强度基本不相关的信息，大气光经雾霾颗粒多次散射后形成的大气散射光为部分偏振光，根据此特性利用多幅具有不同偏振状态的雾霾图像可以估算出大气散射光的强度，从而复原出无雾图像。

基于深度学习的去雾方法通常需要成对的有雾-无雾图像来实现网络训练，然而这种成对的图像在真实世界中很难获取，目前大多只能借助合成数据集来完成模型训练，而合成图像与真实图像之间存在较大差异，可能导致过拟合问题，使应用于真实雾图的去雾效果变差。本课题拟针上述问题，结合偏振光学去雾特性，借助无监督学习网络建立一套基于无监督学习的偏振图像去雾算法。

本课题使用偏振相机采集非配对的偏振有雾-无雾图像近 600 幅，构建了一套可用于偏振去雾研究的数据集。本文提出一种基于斯托克斯参数与暗通道的偏振图像预处理方法，充分利用偏振信息进行初步去雾，将同一场景在不同偏振角（AOP）下的一组图片处理为经过初步去雾的图像。本文通过向改进的循环生成对抗网络（CycleGAN）中引入注意力机制，形成考虑雾霾密度、深度等物理信息的含注意力机制的去雾网络架构，对粗去雾结果进行二次去雾和图像增强。本文进行了大量实验与对比评估，验证了方法的有效性和模型的鲁棒性。

**关键词：**去雾；偏振图像处理；斯托克斯参数；无监督学习；注意力机制

---

# ABSTRACT

Haze is a common atmospheric natural phenomenon. Polarization can provide information that is essentially unrelated to the spectrum and intensity. Atmospheric scattering light formed by multiple scattering of atmospheric light through haze particles is partially polarized light. Utilizing this characteristic, the intensity of atmospheric scattering light can be estimated using multiple haze images with different polarization states, thereby restoring haze-free images.

Deep learning-based dehazing methods usually require paired hazy and haze-free images for network training. However, such paired images are difficult to obtain in the real world. Currently, synthetic datasets are mostly used for model training. The significant differences between synthetic and real images may lead to overfitting, resulting in poor dehazing performance when applied to real hazy images. This project aims to address these issues by combining the characteristics of polarization optics for dehazing and utilizing an unsupervised learning network to establish an unsupervised learning-based polarization image dehazing algorithm.

In this project, approximately 600 unpaired haze and haze-free polarized images were collected using a polarization camera, constructing a dataset for polarization dehazing research. This paper proposes a polarization image preprocessing method based on Stokes parameters and the dark channel, making full use of polarization information for initial dehazing. Images of the same scene under different angles of polarization (AOP) are processed into preliminarily dehazed images. By introducing an attention mechanism into an improved CycleGAN, a dehazing network architecture with an attention mechanism that considers physical information such as haze density and depth is formed. This architecture performs secondary dehazing and image enhancement on the coarse dehazing results. Extensive experiments and comparative evaluations were conducted to verify the method's effectiveness and the model's robustness.

**KEYWORDS:** Dehazing; Polarimetric imaging; Stokes parameters; Unsupervised learning; Attention mechanism

---

# 目 录

<b>1 绪论</b>	1
1.1 课题背景及意义	1
1.2 国内外研究现状	2
1.2.1 偏振图像去雾研究现状	2
1.2.2 单幅图像去雾研究现状	3
1.3 课题研究重点及创新点	4
1.4 本文的组织结构	4
<b>2 基于斯托克斯参数与暗通道的偏振图像去雾方法</b>	5
2.1 数据获取	5
2.2 偏振去雾的数学原理	5
2.2.1 参数确定：大气光 $A$	6
2.2.2 参数确定： $A_{\infty}$	7
2.3 带界面的偏振去雾程序	9
<b>3 含注意力机制的循环生成对抗去雾网络</b>	10
3.1 引言	10
3.2 网络架构	10
3.2.1 整体框架和训练流程	10
3.2.2 网络结构与注意力机制	11
3.3 数据集处理	13
3.4 损失函数	14
<b>4 实验结果</b>	16
4.1 评价指标	16
4.2 偏振粗去雾结果	16
4.3 最终结果	18
<b>5 总结</b>	23
5.1 结论	23
5.2 展望	23
<b>参考文献</b>	25
<b>致谢</b>	28

---

## 插图清单

图 1.1 整体实现流程.....	4
图 2.1 DoFP 图像的分离 .....	5
图 2.2 有雾图像及其暗通道图像.....	8
图 2.3 参数 $s$ 对去雾效果的影响.....	8
图 2.4 偏振去雾程序交互界面.....	9
图 3.1 整体网络框架.....	11
图 3.2 不理想的去雾结果.....	12
图 3.3 CBAM 网络结构.....	13
图 3.4 引入 CBAM 后 $G_D$ 和 $G_d$ 的主要网络结构.....	13
图 4.1 不同场景下偏振粗去雾与暗通道先验去雾结果对比.....	17
图 4.2 改进前后去雾结果对比.....	18
图 4.3 雾浓度与透射率 $t(z)$ 的对应关系 .....	19
图 4.4 不同方法的去雾结果对比.....	19
图 4.5 远景去雾效果对比.....	20
图 4.6 本文方法在光照和色彩处理中的优势.....	21



---

## 表格清单

表 4.1 不同场景下偏振粗去雾与暗通道先验去雾结果的量化评估.....	17
表 4.2 35 幅有雾图像的粗去雾结果平均评估统计值.....	17
表 4.3 远景与近景、有无空域场景下去雾效果量化评估.....	20
表 4.4 薄雾与浓雾场景下去雾效果量化评估.....	20
表 4.5 35 幅有雾图像的最终去雾结果平均评估统计值.....	21
表 4.6 35 幅有雾图像有无预处理时去雾结果平均评估统计值.....	22
表 4.7 透射率为 0.35 的浓雾场景下有无预处理的去雾结果对比.....	22

# 1 绪论

## 1.1 课题背景及意义

作为人类感知世界的视觉基础，图像在信息获取、表达和传递中起着重要作用。雾霾颗粒对光具有强烈的散射和吸收作用，导致收集到的图像出现色差、图像退化和能见度降低等问题，不仅对人们的日常生活造成影响，更在多种场景带来工作阻碍和安全隐患。

图像去雾算法是一种图像分析和处理方法，用于满足特定场景的需求，突出图像细节并增强图像质量。为了提高有雾图像的对比度和能见度，研究者提出了许多去雾算法<sup>[1]</sup>，这些算法大致可以分为基于图像增强的方法、基于图像恢复的方法和基于深度学习的方法<sup>[2]</sup>。图像增强方法主要通过去除图像噪声、提高雾霾图像的对比度和饱和度，以及突出图像的详细特征来恢复图像。然而，图像增强方法通常会导致伪影和恢复图像的地面轮廓不清晰。相比基于图像增强的去雾方法，基于图像恢复的去雾方法得到的图像更接近真实场景。该方法通过解决大气散射物理模型来恢复并获取清晰图像。

传统的光学成像技术基于获取两个基本参数的信息：强度和光谱。其主要缺点是会受到光传播环境的强烈影响。因此，为恢复清晰图像，在雾霾颗粒散射后的低对比度成像环境中引入强度和光谱以外的信息是极为必要的<sup>[3]</sup>。偏振作为光的另一个基本属性是独立于光强信息的。一些自然光在散射、反射和折射后可以形成偏振光。偏振光主要集中在大气光中，可以反映大气光信息，偏振测量也用于大气气溶胶反演研究。近年来，偏振光学成像技术被证明适用于由雾霾或其他散射介质引起的图像退化，清晰图像可以表示为通过偏振相机所获取的偏振信息的函数<sup>[4][5]</sup>。偏振成像可以获取背景和目标的偏振信息，有效去除雾霾颗粒的散射光。因此，偏振成像在理论上可以有效提高图像质量，其突出优点是处理后的图像噪声低、无伪影<sup>[5]</sup>。然而，传统偏振去雾方法基于简化的大气散射模型，这很容易导致颜色偏差，难以应用于不同场景。

近年来，基于深度学习的方法在图像结构和特征提取方面具有显著优势，逐渐成为主流的去雾方法。然而在同一自然场景中，同时收集有雾图像和无雾图像是很困难的<sup>[6]</sup>，因此现有模型大多使用合成的有雾图像数据集进行训练<sup>[7][8]</sup>。然

而合成图像与真实图像之间存在较大差异，可能导致过拟合问题，使应用于真实雾图的去雾效果变差。

因此，针对上述问题，结合偏振光学去雾特性，借助无监督学习网络建立一套基于无监督学习的偏振图像去雾算法是一个重要的研究方向。生成对抗网络（GAN）作为一种无监督学习方法，不依赖成对的训练图像数据集，可以更好地利用颜色、纹理和结构等特征来恢复图像。在图像深度、透射率等物理信息的约束下，经过改进的循环生成对抗网络（CycleGAN）进一步优化了去雾性能。总之，偏振成像和深度学习的有效结合不仅可以充分利用更多的光学信息，还可以借助网络进一步去雾并优化图像，增强偏振去雾方法的泛化性。

## 1.2 国内外研究现状

### 1.2.1 偏振图像去雾研究现状

早在 2001 年，Schechner 等人首次提出了一种成熟的偏振图像去雾方法，使用两个正交偏振图像之间的偏振关系和物体辐射度来实现图像去雾，证明了偏振成像可以有效地提高在雾霾条件下拍摄的图像质量<sup>[9][10]</sup>。近年来，国内外研究人员提出了多种基于偏振成像的图像恢复方法。2014 年，Liang 等人提出了一种利用偏振角估计大气光强度的方法，该方法可以最大限度地抑制直射光的影响<sup>[11]</sup>。2016 年，基于红外辐射在雾霾天气中更好穿透的能力，Liang 等继续提出了一种基于可见光和红外图像融合的偏振去雾方法<sup>[12]</sup>。Zhang 等人利用圆偏振效应（这一效应通常被忽略）进行去雾，圆偏振能够容易地保持图像的偏振特性，并显著提高了去雾效果<sup>[13][14]</sup>。

偏振成像与其他图像恢复方法相结合的方法也陆续提出，并取得了良好的去雾效果。2018 年，Li 等提出了一种将计算机视觉和偏振分析相结合的方法，该方法在稠密混浊介质中的灰度图像恢复方面具有显著的性能<sup>[15]</sup>。近年来，研究人员将深度学习应用于偏振去雾、去散射取得了一定进展，尤其在强散射介质的件下的应用。2020 年，在提出水下图像恢复的密集网络之前，Hu 等使用分焦平面偏振成像系统(DoFP)偏振相机构建了一个包含 140 组图像对的数据集，用于验证基于深度学习的偏振图像处理在除霾方面的优越性。这是第一篇关于用基于深度学习的偏振图像处理进行除雾的报道。2022 年，为了打破对严格配对图像的依赖，该研究团队提出了一种用于水下图像恢复的无监督偏振生成对抗网络，并将

偏振损耗合并到网络中，以增强细节恢复。结果表明，它将图像峰值信噪比(PSNR)值平均提高了 3.4 dB，验证了在不同成像条件下的有效性和优越性<sup>[16]</sup>。

### 1.2.2 单幅图像去雾研究现状

传统单幅图像去雾方法的成功在于使用了更强的先验或假设。2008 年，Tan 等人观察到，无雾图像必须比输入的有雾图像具有更高的对比度，他通过最大化恢复图像的局部对比度来去除雾层<sup>[17]</sup>。Fattal 等假设透射性能和表面阴影在局部上不相关，在此假设下估计场景的反照率和介质传输<sup>[18]</sup>。这种方法在物理上合理，然而它不能很好地处理重度有雾图像。2011 年，He 等率先提出暗通道先验，用于单幅图像去雾<sup>[19]</sup>。暗通道理论认为，无雾图像中非天空区域即使曝光良好，RGB 三个通道中总是存在一个通道的某些像素值很低，接近于 0（黑色）；相比之下，有雾图像暗通道区域远大于 0，呈灰白色。这些暗像素在该通道中的强度主要由大气光贡献。因此，这些暗像素可以直接提供对雾透射的准确估计。

图像去雾与深度学习的结合取得了令人瞩目的成果。为了克服在合成模糊-干净图像对上训练的去雾模型的过拟合问题，近年的许多方法试图通过在未配对数据上训练来提高模型的泛化能力。

2019 年底，Liu 等基于生成对抗网络(GAN)提出了一种基于解纠缠表示的无监督单图像去雾方法<sup>[20]</sup>。该方法不依赖于物理散射模型，也不需要成对的训练数据。团队分别引入一种潜在的回归损失、循环一致性损失以及对抗性损失，以鼓励生成的图像保存和提取雾度信息，确保去雾图像具有与原始图像相同的内容结构，并使去雾图具有相当的视觉真实性。

2020 年，Jin 等提出了一种使用未配对数据集的无监督条件解纠缠网络（UCDN），取代了配对图像或深度信息<sup>[21]</sup>。该方法通过引入基于物理的解纠缠来加强约束。与其他无监督除雾模型相比，该方法适应了雾的多浓度，并在不同浓度的数据集上表现出色。

2022 年，Yang 等考虑到真实世界雾环境的物理特性，即雾度随密度和深度而变化，提出了一种自增强图像去雾框架，称为 D4（通过密度和深度分解的自增强、非配对图像去雾），用于生成和去除雾<sup>[22]</sup>。所提出的框架不只是估计透射图或干净图像，而是专注于探索有雾图像和干净图像中包含的散射系数和深度信息。通过估计场景深度，该方法能够重新渲染不同厚度的模糊图像，这进一步有利于去雾网络的训练。

### 1.3 课题研究重点及创新点

基于深度学习的偏振去雾方法通常需要成对的有雾-无雾图像来实现网络训练，然而这种成对的图像在真实世界中很难获取，目前大多只能借助合成数据集来完成模型训练，然而合成图像与真实图像之间存在较大差异，可能导致过拟合问题，使应用于真实雾图的去雾效果变差。此外，基于深度学习的单幅图像去雾方法只依赖于单一的图像信息，其去雾结果存在一定局限性。利用偏振成像设备采集到的不同偏振角下的雾霾图像可以为神经网络提供更加全面的图像信息。

针对上述问题，本文首先提出一种基于斯托克斯参数（Stokes Parameters）和暗通道的偏振图像去雾方法，对偏振组图进行预处理。通过向改进的循环生成对抗网络（CycleGAN）中引入注意力机制，本文形成一种考虑雾密度、深度等物理信息的含注意力机制的去雾网络架构，用于对经过预处理的图像进行二次去雾和图像增强。本文在具有不同雾浓度和特征的场景进行大量实验，结果表明该方法可以有效提高图像质量，增强有雾图像的对比度和能见度，并对不同雾环境具有良好的鲁棒性。整体实现流程如图 1.1 所示。




图 1.1 整体实现流程

### 1.4 本文的组织结构

第一章对偏振图像去雾、单幅图像去雾等研究现状做了总结，并针对本文描述的基于无监督学习的偏振去雾课题进行了概述。

第二章阐述了偏振图像去雾的物理原理，并对本文提出的基于斯托克斯参数和暗通道的偏振图像去雾方法进行了描述。

第三章围绕基于无监督学习的去雾方法，对数据集、本课题所使用的循环生成对抗网络结构以及向网络中引入的注意力机制进行介绍。

第四章对本文所建立的去雾方法进行测试与结果展示，并通过和其他去雾方法的性能对比证明本文方法的优越性。

第五章对全文工作和当前研究尚存的挑战进行了总结。

## 2 基于斯托克斯参数与暗通道的偏振图像去雾方法

### 2.1 数据获取

用于做去雾处理的数据来自偏振相机实拍。本文使用的偏振相机型号为 10 GigE HR-12000-S-PC，该相机配备了索尼的 IMX253MYR 偏振传感器。单个像素包含有四个不同角度的偏振器（0, 45, 90, 135 度），每组四个像素作为一个计算单元。因此，相机可以同时拍摄同一场景在四个偏振角下的分焦平面（DoFP）图像。如图 2.1 所示，经过分离，每幅 DoFP 图像被拆分为偏振角（AOP）分别为 0, 45, 90, 135 度的一组图像，大小为 2048×1500 像素。




图 2.1 DoFP 图像的分离

### 2.2 偏振去雾的数学原理

在计算机视觉领域，通常使用雾天图像退化模型来描述雾霾等恶劣天气条件对图像造成的影响，该模型由 McCartney 在 1977 年首先提出。又根据 Koschmieder 模型<sup>[23][24]</sup>，在雾霾天气中，相机接收到的总辐照度  $I$  由目标的衰减反射光的辐照度  $D$  和部分偏振大气光的辐照度  $A$  组成。雾天图像可以由待恢复的有雾图像表示为：

$$I(z) = D + A = J(z)t(z) + A_{\infty}(1 - t(z)) \quad (2-1)$$

$$t(z) = e^{-\beta d(z)} \quad (2-2)$$

该模型包括衰减模型和环境光模型两部分。公式（2-1）中， $z$  是拍摄图像中物体与拍摄者之间的空间距离， $I(z)$  是观察到的有雾图像， $J(z)$  是待恢复的无雾图像， $t(z)$  表示透射率， $\beta$  表示大气散射系数， $d$  代表景物深度， $A_{\infty}$  是无穷远处大气光，通常情况下假设为全局常量，与空间坐标  $z$  无关。由此可见，图像去雾过程就是根据  $I(z)$  求解  $J(z)$  的过程。

根据公式（1），待恢复的无雾图像 $J(z)$ 可以表示为：

$$J(z) = \frac{I(z) - A_{\infty}(1 - t(z))}{t(z)} \quad (2-3)$$

又有 $A = A_{\infty}(1 - t(z))$ ，则上式可以改写为：

$$J(z) = \frac{I(z) - A}{1 - A/A_{\infty}} \quad (2-4)$$

由公式（2-4）可知，确定主要参数 $A$ 和 $A_{\infty}$ 即可推导出清晰图像。

### 2.2.1 参数确定：大气光 $A$

将 2.1 中使用偏振相机采集并处理所得的偏振角为 0, 45, 90 和 135 度的图像分别用 $I_0$ ,  $I_{45}$ ,  $I_{90}$ ,  $I_{135}$ 来表示，则斯托克斯参数可以定义为：

$$\begin{cases} S_0 = I_0 + I_{90} \\ S_1 = I_{90} - I_0 \\ S_2 = I_{135} - I_{45} \\ S_3 = I_r - I_l \end{cases} \quad (2-5)$$

其中， $S_1$ 代表水平方向或垂直方向的光强度差异， $S_2$ 代表 $\pm 45^\circ$  偏振方向的光强度差异， $I_r$ 和 $I_l$ 分别代表右旋偏振光和左旋偏振光， $S_3$ 代表左旋和右旋圆偏振分量之间的光强度差异。由于需要安装四分之一波片才能获取圆偏振光，因此 $S_3$ 无法被获取，计算时通常简单地将 $S_3$ 设为 0。 $S_0$ 代表总入射光强度，即无偏图像 $I(z)$ 。在计算中，我们首先将 $I_0$ 和 $I_{90}$ 在 R、G、B 三个通道上进行分离，随后将三个色彩通道上的灰度值相加，归一化后重新合成为彩色图像，作为 $S_0$ 。需要注意的是，在进行归一化时需要注意尺度的一致性，即使用 R、G、B 中的最大（小）强度值作为所有通道的归一化上（下）限，如果三个通道独立地进行归一化，则会出现色偏问题。

基于公式（2-5），可以求得每个像素点上的偏振角 $\theta$ ：

$$\theta = \frac{1}{2} \tan^{-1} \left( \frac{S_2}{S_1} \right) \quad (2-6)$$

偏振角的最大优势在于，由于其独立于 $S_0$ ，几乎不受非偏振光的干扰。这意味着，与直接通过斯托克斯参数计算得到的偏振度（DOP）相比，偏振角可以提供更精确的大气光信息。我们采用公式（2-7）来表示每个像素点上的偏振度：

$$P = \frac{\sqrt{S_1^2 + S_2^2}}{S_0} \quad (2-7)$$

我们将所有像素点中出现频率最高的偏振角视为大气光偏振角，记作 $\theta_A$ ，则大气光的偏振分量辐射 $A_{pcr}$ 可以表示为<sup>[11]</sup>：

$$A_{pcr} = \frac{I_0 - S_0(1 - P)/2}{\cos^2 \theta_A} \quad (2-8)$$

我们找出 $\theta$ 等于 $\theta_A$ 的像素点，大气光的偏振度 $P_A$ 可以估计为这些像素点上 $P$ 的最大值。由此，第一个关键参数 $A$ 最终可以通过以下表达式进行估计<sup>[10]</sup>：

$$A = A_{pcr} / P_A \quad (2-9)$$

### 2.2.2 参数确定： $A_\infty$

之前的研究中在确定无穷远处大气光 $A_\infty$ 时，首先对 $A_\infty(z \rightarrow \infty)$ 进行建模，随后一一比较每个像素点上 $A_\infty(z \rightarrow \infty)$ 与 $S_0$ 的强度值，筛选出其中差距小于 5% 的点，最后选出这些点上 $A_\infty(z \rightarrow \infty)$ 的最大值作为 $A_\infty$ <sup>[12]</sup>。这种方法精确度高，但是计算量庞大，考虑到本文所采集的偏振图像分辨率大小为 2048×1500，这种方法往往会导致计算内存不足。另一种快速确定 $A_\infty$ 的方法在 $\theta$ 等于 $\theta_A$ 的像素点上选出大气光 $A$ 的最大值作为 $A_\infty$ ，这种方法计算量小，但是精确度较差。在实验中该方法作用于本文所用数据集的效果并不理想。因此，本文采用暗通道理论<sup>[19]</sup>估计参数 $A_\infty$ 。

彩色图像通常包括三个通道，即红、绿、蓝（RGB）三通道，图像由像素组成，每个像素的颜色由这三种原色的组合表示。暗通道的概念是指，在清晰无雾的图像中，除天空区域外（天空区域或白色区域的特性与雾较为相似），任一局部区域的像素至少有一个通道值非常低，几乎接近于 0（黑色）。暗通道图像的计算方法如下：

首先计算每个像素在三个通道中的最小值，得到一张与原始图像大小一致的灰度图。随后使用最小值滤波对灰度图进行平滑处理，即在得到的灰度图中，以每一个像素为中心取一定大小的矩形窗口，用矩形窗口中灰度值的最小值代替中心像素的值，从而生成原始图像对应的暗通道图像 $I_{dark}$ 。

在图像中，雾浓度越低，其暗通道图越暗；雾浓度越高，其暗通道图越亮，像素点值越大。图 2.2 展示了暗通道对雾浓度的反映效果。本文对于 $A_\infty$ 的选取方法为：首先在 $I_{dark}$ 中选出前 0.1% 像素值最大的像素点，这些像素点通常表示雾霾图像中最不透明的点。将这些点对应到 $S_0$ 中，选取最高的像素点值作为无穷远大气光 $A_\infty$ 。






图 2.2 有雾图像及其暗通道图像

至此，主要参数 $A$ 和 $A_\infty$ 得以确定，根据公式(2-4)即可初步恢复出无雾图像。本文采用的计算方法为分别在 $I(z)$ 的三个色彩通道上遍历所有像素点进行去雾运算。本文向公式(2-4)中额外引入去雾强度参数 $s$ ：

$$J(z) = \frac{I(z) - A}{1 - s \cdot A / A_\infty} \quad (2-10)$$

图 2.3 参数 $s$ 对去雾效果的影响

如图 2.3 所示，实验中，去雾效果和图像对比度随参数 $s$ 增大而上升，图像质量随参数 $s$ 增大而下降。更大 $s$ 提升了远景去雾效果，但使图像出现更多噪点，更

大的对比度导致近景物体成像变暗。考虑到后续使用网络模型进一步去雾，我们一般将 $s$ 的取值区间设置为 $[0.65, 0.95]$ ，希望为深度学习提供信息量更大、成像素质更均衡的粗去雾数据集，并借助深度学习达到二次去雾与图像优化的目的。

### 2.3 带界面的偏振去雾程序

本文借助 MATLAB 的 App Designer 工具，基于 2.2 中所述偏振去雾原理，设计出一款带界面的偏振去雾程序，以便将理论方法包装为用户友好型的工具。程序包括选择待处理图片、调整去雾强度参数 $s$ 、进行偏振去雾、调整结果亮度、保存去雾结果等功能，并可以时时显示原图及经过处理的图片的各项质量评估指标，包括信息熵、标准差等内容。输入数据应为统一命名的 AOP 为 0, 45, 90, 135 度偏振图像以及无偏图 $S_0$ ，用户需确保这些文件夹分别放在同一文件夹下且同一场景的一组图像有相同命名。输入图片时用户从 $S_0$ 中选择想要去雾的图片，程序会自动读取同名的 0, 45, 90 和 135 度偏振图像，进行去雾处理。得到去雾结果后，用户可以拉动滑块调整图像亮度，并将最终结果保存到本地。



图 2.4 偏振去雾程序交互界面

### 3 含注意力机制的循环生成对抗去雾网络

#### 3.1 引言

CycleGAN<sup>[25]</sup>是一个广泛采用的非配对图像到图像转换框架。一方面，GAN 损失用于强制图像在两个域之间转换；另一方面，循环重建损失则有效地保持内容一致性。在图像去雾方面，基于 CycleGAN 的方法<sup>[20][21]</sup>通常包含一个去雾网络和一个再雾网络，它们从有雾图像中预测出清晰图像或从清晰图像生成有雾图像，二者相互对抗。

然而，一般的 CycleGAN 没有考虑雾浓度、深度等物理特性。其生成的雾通常缺少真实感和变化性，很容易局限于合成固定浓度的灰白色模糊图层，这进一步影响了去雾网络的学习。现实世界中雾霾的特性和分布与透射率、场景深度等因素密切相关，而面向实际应用的户外去雾也必须面对拍摄场景中同时存在远景与近景，即远处浓雾与近处薄雾的情况。

为了解决这些问题，达到去雾和优化粗去雾结果的目的，本文基于现有架构，引入 CBAM（Convolutional Block Attention Module）注意力模块<sup>[26]</sup>，形成一种基于 CycleGAN 的含注意力机制并考虑密度和深度等物理特性的无监督去雾框架。此外，现有模型所使用的清晰图像数据集大多质量欠佳，本文通过优化数据集进一步提升无监督学习效果。

#### 3.2 网络架构

##### 3.2.1 整体框架和训练流程

整体循环生成对抗架构由“去雾-生成雾”和“生成雾-去雾”两个分支组成，如图 3.1 所示。雾图数据集 $H_i$ 和清晰数据集 $C_i$ 是两组真实图集的样本空间。和严格配对有雾-无雾数据集不同，这两组合集不存在任何配对关系，图片数量也不必一致。根据公式（1）（2），在已知透射率 $t(z)$ 的条件下即可由有雾图得到清晰图或由清晰图得到有雾图，而 $t(z)$ 由散射系数 $\beta$ 和深度 $d(z)$ 决定。

去雾-生成雾分支

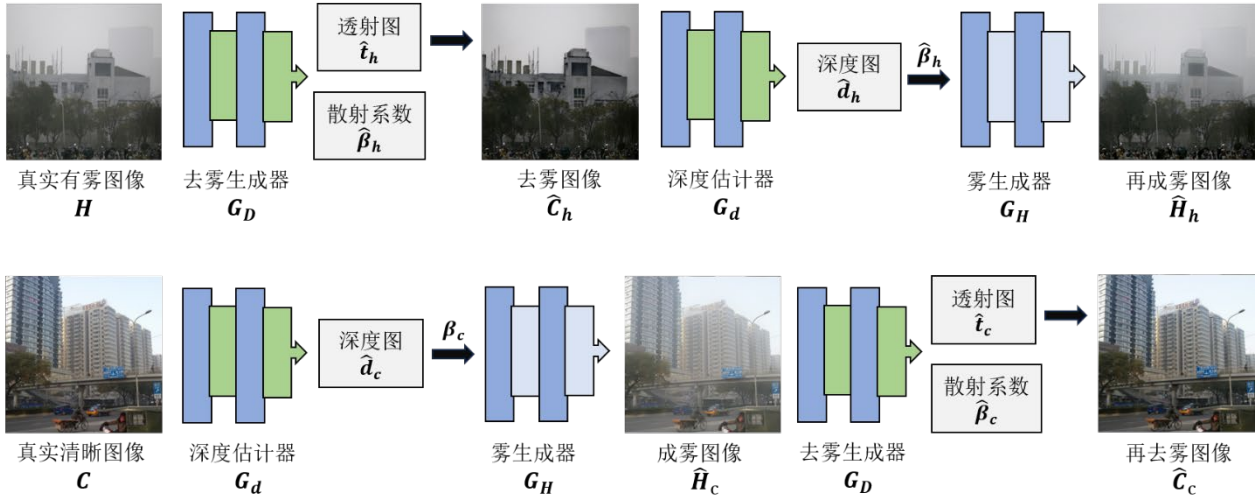


图 3.1 整体网络框架

架构包括三个主要网络：去雾生成器 $G_D$ 、深度估计器 $G_d$ 以及雾生成器 $G_H$ 。在“去雾-生成雾”分支上，去雾生成器 $G_D$ 首先估计出输入有雾场景 $H$ 的透射图 $\hat{t}_h(z)$ 和散射系数 $\hat{\beta}_h$ ，以此复原出清晰图像 $\hat{C}_h$ 。 $\hat{C}_h$ 随后被送入深度估计器 $G_d$ 得到深度 $\hat{d}_h$ ，结合散射系数 $\hat{\beta}_h$ 通过雾生成器 $G_H$ 生成雾图 $\hat{H}_h$ 。

在“生成雾-去雾”分支上，深度估计器 $G_d$ 由输入的清晰图像 $C$ 得到其深度信息 $\hat{d}_c$ ，随后在限定范围内随机给出的散射系数 $\beta_c$ ，雾生成器 $G_H$ 由此合成具有一定密度的有雾图像 $\hat{H}_c$ ，最后通过去雾生成器 $G_D$ 得到清晰图像 $\hat{C}_c$ 。在这个过程中，所给散射系数 $\beta_c$ 影响生成雾图的雾浓度。本文用于训练的有雾数据集为经过偏振粗去雾的预处理结果，粗去雾的过程基于物理原理而不包含生成过程，图像依然符合雾图特性，只是雾霾在密度上有所下降，因此我们进一步下调了给定 $\beta_c$ 的取值上限。实验结果验证了这种处理的有效性，更多关于数据集的准备和处理将在下一节中进行详细介绍。

### 3.2.2 网络结构与注意力机制

雾生成器 $G_H$ 则主要基于 U-Net<sup>[27]</sup>结构进行架设，本文额外在前向网络中为无雾图像随机添加程度较轻的高斯噪声，以贴近有雾图像在预处理过程中可能出现的轻微噪点。去雾生成器 $G_D$ 和深度估计器 $G_d$ 主要基于 EfficientNet-lite3<sup>[28]</sup>结构。EfficientNet 系列是由 Google 于 2019 年推出的主要用于图像分类任务的网络模型，EfficientNet-lite3 是系列其中一种轻量化版本，在保持高精度的同时进一步



缩减模型参数和计算量。该网络模型基于复合缩放（Compound Scaling）方法，该方法同时缩放网络的深度（网络层数）、宽度（通道数）和输入分辨率，以达到最优的计算效率和模型性能。本文在去雾生成器 $G_D$ 和深度估计器 $G_d$ 中加载预训练的 EfficientNet-lite3 模型对输入图像进行特征提取，共设置四层，通道数依次为 32, 48, 136, 384 逐层扩展。本文向 $G_D$ 和 $G_d$ 中分别引入四层 CBAM 注意力机制，下面将对注意力机制进行介绍。

注意力在人的感知中起着重要作用。人类视觉系统的一个重要特性是不会尝试一次处理整个场景，而是选择性地关注显著部分，以更好地处理视觉信息、感知场景结构<sup>[29]</sup>——在深度学习领域，同样需要某种注意力机制起到引导网络模型更多或更少地关注特征。

注意力不仅指示应该关注的位置，还能改善感兴趣区域的表示能力。以本文需要处理的有雾图像为例，我们希望通过使用注意力机制，使网络关注重要特征，如有雾区域、远景区域等，同时抑制不必要的特征，如雾密度低的区域、近景区域。图 3.2 展示了未引入注意力机制的训练结果中存在的问题，如出现未能完全去雾的带状区域、近处物体的过度去雾导致成像过暗等现象。



图 3.2 不理想的去雾结果

本文向网络同时引入通道注意力机制和空间注意力机制。通道注意力机制用于建模特征通道间的相关性，学习不同通道的重要性；空间注意力机制用于重点关注图像的局部区域。卷积模块注意力机制（CBAM）是通道注意力与空间注意力的一种融合机制，其结构如图 3.3 所示。CBAM 使用卷积块注意力模块来强调沿这通道和空间这两个主要维度的有意义特征，即依次应用通道和空间注意力模块，使每个分支分别学习在通道和空间轴上应该关注什么、关注哪里。简单来说，

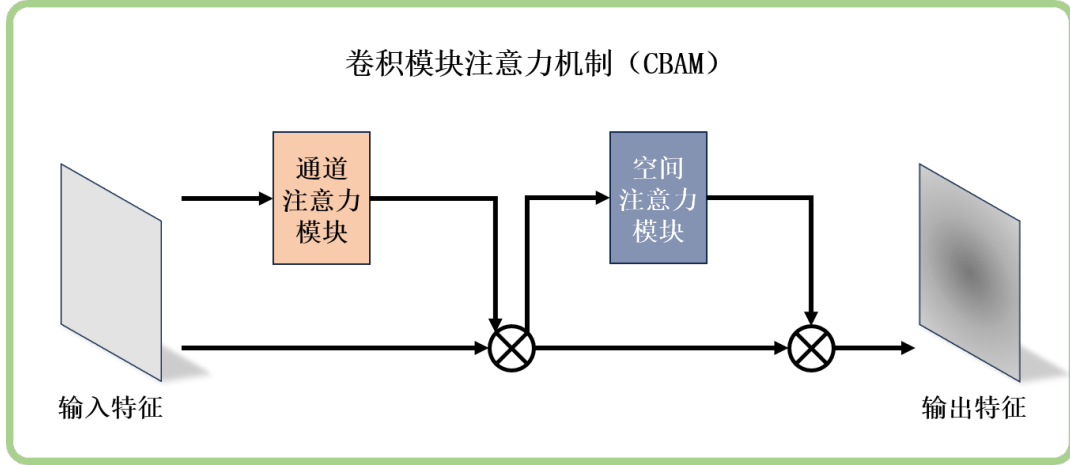



图 3.3 CBAM 网络结构

就是首先将通道注意力提取出的特征与输入特征相乘，送入空间注意力模块，将结果再次与输入特征相乘。CBAM 通过学习要强调或抑制哪些信息，有效增强了网络内的信息流动。

本文向 $G_D$ 和 $G_d$ 中分别引入四层 CBAM，具体排列结构如图 3.4 所示。我们在每层预加载的 EfficientNet-lite3 网络模型后衔接一层 CBAM，通过 EfficientNet-lite3 提取的特征被送入先后送入通道注意力和空间注意力模块中，随后衔接下一层 EfficientNet-lite3 网络。实验结果验证了 CBAM 在网络中的增强效果。添加了注意力机制的网络模型取得了更高的去雾性能，并且在去雾时能更好地处理远近景关系，有效抑制了去雾后由于对比度增强而导致近处物体成像过暗的问题。


 图 3.4 引入 CBAM 后 $G_D$ 和 $G_d$ 的主要网络结构

### 3.3 数据集处理

本文在实验中使用的有雾图像数据集均由偏振相机真实采集。用于训练的数

数据集是经过前级偏振粗去雾的预处理结果。如前文所述，不同的去雾强度参数 $s$ 会影响成像质量。为了确保给网络尽可能提供最丰富的特征信息用于学习，本文分别在 $s$ 取值 0.65, 0.75, 0.95 三种条件下对所有数据进行粗去雾，随后依次求取去雾图像的信息熵，将取得最大信息熵的图像选出，构成用于网络训练的有雾图像数据集。

用于训练的清晰图像由偏振相机在无雾环境下拍摄并还原的无偏图像与开源数据集 SOTS-outdoor 筛选合并而来。本文在实验中发现，以往的研究<sup>[20][21][22]</sup>在训练网络时惯用的开源数据集（如 OTS、SOTS-outdoor 等）质量参差不齐，除分辨率较低外，清晰图像往往采集自无云的晴天，图像中有明烈的阳光照射和光影对比；有雾图像大多由清晰图像合成而来，甚至出现如阳光充足的晴天场景蒙上灰白色图层作为有雾图像的情况。这显然是不符合实际的。

本文认为，用于无监督学习去雾的数据集更需要重视其合理性，理想的去雾并非将一张有雾图像改变为有蓝色天空和充足阳光的场景，而是基于场景本身的环境表现，去除雾层得到当前环境光下的无雾图像。光影对比强烈的清晰图像数据集很有可能导致训练模型过度增大对比度，影响无雾或薄雾区域的成像质量，可能在一定程度上导致了诸如近景成像过暗等问题的出现。

因此，本文在进行训练前对清晰图像数据集的建立进行严格筛选，实拍的清晰图像均来自无雾的多云天气或无明显光影对比的环境，得益于偏振光学优势，这些图像受反射、折射光或眩光的影响更小，整体成像素质较高。为进一步扩充数据集，本文从开源数据集 SOTS-outdoor 中筛选出符合上述要求的清晰图像作为无雾数据集的补充，得到无雾数据集共计 550 幅，有雾数据集共计 500 幅。本文使用水平翻转等数据增强方法对数据集进行扩充，最终得到用于训练的无雾数据集 1100 幅，有雾数据集 1000 幅。

### 3.4 损失函数

我们将三个网络一起训练以执行去雾和再雾循环。与 CycleGAN 类似，循环一致性损失和对抗训练损失分别用于约束内容一致性和数据分布。此外，散射系数损失和深度损失分别被用于从无配对的有雾-无雾图像中学习密度和深度等物理特性。

循环一致性损失要求从一个域转换到另一个域的中间图像应能够转换回来。在本文的网络中，重构的清晰图像 $\hat{C}_c$ 和有雾图像 $\hat{H}_h$ 应与其输入所对应的 $C$ 和 $H$ 一

致。 $C_i$ 和 $H_i$ 分别表示清晰数据和有雾数据集的样本空间， $\|\cdot\|_1$ 表示L1范数，即向量中各个元素绝对值之和。则循环一致性损失可以写成如下形式：

$$L_{cyc} = \mathbb{E}_{C \sim C_i} \|C - \hat{C}\|_1 + \mathbb{E}_{H \sim H_i} \|H - \hat{H}\|_1 \quad (3-1)$$

对抗损失评估生成的图像是否属于特定域，即评估网络生成的去雾和再生成雾图像在视觉上是否真实、是不是符合训练集 $H_i$ 和 $C_i$ 中图像的分布。本文采用最小二乘损失函数（LSGAN）。LSGAN 会惩罚远离决策边界的判别为真的样本，并把远离决策边界的假样本拖进决策边界<sup>[30]</sup>，因此在稳定性和视觉质量方面表现出色。对于去雾网络 $G_D$ 及其相应的判别器 $D_c$ ，对抗损失可以表示为：

$$L_{adv}(D_c) = \mathbb{E}[(D_c(C) - 1)^2] + \mathbb{E}[(D_c(\hat{C}_h))^2] \quad (3-2)$$

$$L_{adv}(G_D) = \mathbb{E}[(D_c(\hat{C}_h) - 1)^2] \quad (3-3)$$

其中， $C$ 是来自清晰图像集 $C_i$ 的真实无雾样本， $\hat{C}_h$ 是由 $G_D$ 生成的去雾结果， $D_c$ 是判断输入图像是否属于无雾样本空间的判别器。成雾网络 $G_H$ 及其对应的判别器 $D_H$ 的对抗损失形式相同。

在“生成雾-去雾”分支中，散射系数损失用于评估和惩罚随机采样的散射系数 $\beta_c$ 和从生成雾图 $\hat{H}_c$ 中估计的散射系数 $\hat{\beta}_c$ 之间的差异。本文使用均方误差（MSE, Mean Squared Error）来定义该损失：

$$L_\beta = (\hat{\beta}_c - \beta_c)^2 \quad (3-4)$$

在生成雾的过程中，深度估计网络 $G_d$ 从输入图像中估计出场景深度。在“去雾-生成雾”分支中， $G_d$ 从去雾图像 $\hat{C}_h$ 估计出深度图 $\hat{d}_h$ ，即 $\hat{d}_h = G_d(\hat{C}_h)$ ；我们把 $G_d$ 从输入有雾图像 $H$ 中估计出的深度图 $d_h$ 作为伪真实值，即 $d_h = G_d(H)$ 。使用L1范数将深度监督损失定义为：

$$L_d = \|\hat{d}_h - d_h\|_1 \quad (3-5)$$

总体而言，深度估计网络 $G_d$ 单独通过深度损失 $L_d$ 进行优化，其余模块通过循环损失、对抗损失和散射系数损失的加权组合进行优化，即：

$$L_{\text{总}} = w_{cyc}L_{cyc} + w_{adv}L_{adv} + w_\beta L_\beta \quad (3-6)$$

其中， $w_{cyc}$ ， $w_{adv}$ 和 $w_\beta$ 是平衡不同项的权重，可以在配置文件中根据实验情况进行修改。本文将权值设为 $w_{cyc} = 1$ ， $w_{adv} = 0.2$ ， $w_\beta = 1$ 。



## 4 实验结果

### 4.1 评价指标

由于本文对采集的雾图直接进行去雾处理，在无监督学习中也不存在成对的有雾-无雾图像，因此无法通过与理想状态的对比进行有参考的评估（如峰值信噪比等指标）。本文主要采用以下指标对去雾结果进行无参考的评估：

信息熵：图像的信息熵用于反映图像包含信息量，信息熵越大表明图像的信息量越多；均值：均值是指图像像素的平均值，它反映了图像的平均亮度。均值越高，平均亮度越大；标准差：标准差反映图像像素值与均值的离散程度，标准差越大表明图像灰度级别越分散、图像边缘越清晰，图像质量越好；平均梯度：平均梯度反映了图像的清晰度和纹理变化，平均梯度越大说明图像越清晰。

本文所有指标的量化计算均通过 MATLAB 完成，分别在输入彩色图像的 R、G、B 三个通道上计算后取平均值作为最终结果。

此外，依据公式（2-4）得到透射率 $t(z)$ 的计算方法如下：

$$t(z) = 1 - A/A_{\infty} \quad (4-1)$$

透射率 $t(z)$ 用于定量评估待处理的有雾图像的雾浓度大小。 $t(z)$ 值越小表明雾越浓。

### 4.2 偏振粗去雾结果

实验首先使用通过 MATLAB 实现的偏振去雾方法对我们采集的有雾图像进行去雾处理。如章节 2.2 中所述，更高的参数带来更好的中远景去雾效果，但同时导致图像损失严重，近景成像变暗。本文在实验中一般取参数 $s = 0.75$ 以得到较为均衡的粗去雾结果。

图 4.1 和表 4.1 展示了在不同场景下本方法与暗通道先验去雾的结果对比及各项性能指标。我们从本文采集的真实有雾数据集中抽取 35 张样本，表 4.2 是 35 幅有雾图像的去雾结果评估指标的平均统计值。经过观察对比，暗通道先验的远景去雾性能在多个场景中略优于本文的粗去雾方法，但其去雾结果多呈现暗沉、色彩失真（偏黄或偏紫）的情况。表 4.1、表 4.2 中其均值较低也反映了处理后图像亮度的损失，本文的粗去雾方法较好地与原图维持了空域光照情况的一致性，亮度损失更低。量化评估表明，本文的偏振粗去雾方法作为输入网络模型的前级，

在进行初步去雾的同时为后级网络提供了更充分的图像信息。




图 4.1 不同场景下偏振粗去雾与暗通道先验去雾结果对比

表 4.1 不同场景下偏振粗去雾与暗通道先验去雾结果的量化评估

量化指标	图 4.1 (a)			图 4.1 (b)			图 4.1 (c)		
	原图	本文粗去雾法	暗通道先验法	原图	本文粗去雾法	暗通道先验法	原图	本文粗去雾法	暗通道先验法
信息熵	7.47	<b>7.70</b>	7.11	7.21	<b>7.39</b>	7.27	7.10	<b>7.36</b>	7.02
均值	<b>130.82</b>	100.74	89.59	<b>146.12</b>	126.61	107.19	<b>139.66</b>	119.40	92.91
标准差	57.90	<b>70.50</b>	63.23	54.11	<b>62.65</b>	59.57	35.65	<b>42.90</b>	34.70
平均梯度	12.39	<b>17.84</b>	14.49	11.06	<b>13.83</b>	12.93	11.53	16.11	<b>18.46</b>

表 4.2 35 幅有雾图像的粗去雾结果平均评估统计值

量化指标	原图	本文粗去雾法	暗通道先验法
信息熵	7.21	<b>7.33</b>	6.94
均值	<b>120.59</b>	103.51	82.40
标准差	48.45	<b>54.28</b>	48.36
平均梯度	20.34	<b>23.79</b>	21.97

### 4.3 最终结果

本文使用的数据集在章节 3.3 中已有详细介绍。通过改进数据集、引入注意力机制等措施，本文训练得到的去雾模型改进了近处无雾区域成像过暗、去雾带状不均等问题，去雾稳定性也得到极大提升，批量去雾的良品率明显改观，几乎没有出现黑斑等严重的画面失真。改进前后的结果对比如图 4.2 所示。





图 4.2 改进前后去雾结果对比

在图 4.2 (a)和(b)中，可以轻易看出引入注意力机制前去雾出现的带状残留。我们猜测这种带状去雾不均是由于训练中模型所关注的图像区域边界不够精细，不能处理好场景深度变化带来的雾浓度信息的变化。引入注意力机制后的网络基本解决了这一现象。图 4.2(c)和(d)直观地展示了改进前后图像对比度以及无雾区域亮度的差别，我们的模型很好地处理了空间和场景深度关系。

量化评估方面，我们首先依据公式 (4-1) 定量衡量待处理样本的雾浓度，雾浓度与透射率 $t(z)$ 的对应关系如图 4.3 所示。


 图 4.3 雾浓度与透射率 $t(z)$ 的对应关系

我们将本文方法分别与暗通道先验去雾、AOD-Net<sup>[31]</sup>在有无空域、景物远近、薄雾、浓雾等多种环境进行对比，结果如图 4.4 和表 4.3、表 4.4 所示。




图 4.4 不同方法的去雾结果对比

从实验结果来看，在包含空域的复杂场景中，本文方法很好地还原了天空的光照情况，如图 4.4 (a)所示；在不含空域的近距离场景以及在光照良好的薄雾场景中很好地控制了亮度（均值）损失，整体视觉效果更加通透，如图 4.4 (b)和(c)所示；在透射率不高于 0.40 的浓雾场景中，本文方法不仅在清晰度上领先于其他方法，而且避免了色彩失真，如图 4.4 (d)所示。表 4.3、表 4.4 表明，本文的处理结果在各种场景中都取得了标准差和平均梯度的优势。



表 4.3 远景与近景、有无空域场景下去雾效果量化评估

量化指标	图 4.3 (a)				图 4.3 (b)			
	原图	本文方法	暗通道先验法	AOD-Net	原图	本文方法	暗通道先验法	AOD-Net
信息熵	7.50	<b>7.54</b>	7.30	7.30	<b>6.82</b>	6.78	6.29	6.50
均值	<b>125.07</b>	84.37	87.76	70.85	<b>104.53</b>	56.10	58.77	44.69
标准差	53.05	<b>65.84</b>	57.16	55.91	28.05	<b>29.76</b>	20.80	24.37
平均梯度	18.79	<b>27.56</b>	21.74	25.47	23.96	<b>35.75</b>	25.12	31.90

表 4.4 薄雾与浓雾场景下去雾效果量化评估

量化指标	图 4.3 (c)				图 4.3 (d)			
	原图	本文方法	暗通道先验法	AOD-Net	原图	本文方法	暗通道先验法	AOD-Net
信息熵	<b>7.17</b>	6.91	6.70	6.31	7.10	<b>7.33</b>	7.02	7.11
均值	<b>81.67</b>	51.62	52.19	34.07	<b>139.66</b>	83.54	92.91	80.24
标准差	<b>44.09</b>	41.42	34.18	33.31	35.65	<b>46.62</b>	34.70	36.82
平均梯度	37.64	<b>41.43</b>	34.90	41.17	11.53	<b>21.85</b>	15.80	18.46



图 4.5 远景去雾效果对比

图 4.5 展示了不同方法的远景去雾表现，我们的方法在保证天空亮度的同时较好地对远景雾霾进行去除；图 4.6 进一步展示了我们的方法在维持光照和色彩一致性上，以及提高视觉通透感的出色表现。




图 4.6 本文方法在光照和色彩处理中的优势

我们使用不同方法对 35 张雾图样本进行批量处理，平均指标统计如表 4.5 所示，验证了本文方法在提升标准差和平均梯度方面的优势。

表 4.5 35 幅有雾图像的最终去雾结果平均评估统计值

量化指标	原图	本文方法	暗通道先验法	AOD-Net
信息熵	7.21	<b>7.24</b>	6.94	6.91
均值	<b>120.59</b>	81.16	82.40	68.64
标准差	48.45	<b>58.73</b>	48.36	50.24
平均梯度	20.34	<b>28.34</b>	21.97	26.58

另外，实验验证了偏振去雾预处理环节对整体去雾效果的提升。我们分别使用网络模型处理原图样本与经过偏振预处理的样本，平均处理结果如表 4.6 所示。实验结果表明，有偏振预处理环节的最终结果相较直接处理结果亮度略低，但去雾更加理想，尤其是在透射率低于 0.4 的浓雾环境下。如在图 4.3  $t(z) = 0.35$  的场景中，有偏振预处理环节的去雾结果相比缺少偏振预处理环节的去雾结果，在标准差上高出 20.50%，在平均梯度上高出 52.37%，具体结果如表 4.7 所示。实验证明，偏振预处理显著改善了最终去雾性能。

表 4.6 35 幅有雾图像有无预处理时去雾结果平均评估统计值

量化指标	原图	有偏振预处理	无偏振预处理
信息熵	7.21	7.24	<b>7.29</b>
均值	<b>120.59</b>	81.16	90.42
标准差	48.45	<b>58.73</b>	57.43
平均梯度	20.34	<b>28.34</b>	27.09

表 4.7 透射率为 0.35 的浓雾场景下有无预处理的去雾结果对比

量化指标	原图	有偏振预处理	无偏振预处理
信息熵	7.23	<b>7.60</b>	7.55
均值	<b>152.66</b>	94.24	123.79
标准差	37.97	<b>58.61</b>	48.64
平均梯度	17.21	<b>37.56</b>	24.65

## 5 总结

### 5.1 结论

本课题的主要工作是，发挥偏振光学优势，借助无监督学习网络进行深度去雾。深度学习已经成为解决图像去雾问题的重要手段之一，然而基于配对数据集的训练难以获取真实样本，而借助合成数据集来完成的训练使应用于真实雾图的去雾效果变差。

针对上述问题，本文的主要工作内容概括为：

（1）详细介绍了国内外在偏振去雾和基于无监督学习的单幅图像去雾领域的研究现状，总结了当前研究存在的主要问题；

（2）基于斯托克斯参数和暗通道理论，提出一种偏振图像粗去雾方法，对偏振组图进行预处理，并基于 MATLAB App Designer 设计了一款有可视化界面的偏振去雾程序；

（3）向改进的循环生成对抗网络中引入 CBAM 注意力机制，形成一种考虑雾霾密度、深度等物理信息的含注意力机制的去雾网络架构，用于对经过预处理的图像进行二次去雾和图像增强；

（4）建立了一套可供后续研究使用的非配对的偏振真实图像数据集。本文对用于无监督学习的清晰图像数据集进行筛选，提出一种数据集的优化思路；

（5）使用不同的网络参数在不同雾浓度和特征的场景下进行大量实验，验证了方法的去雾性能，证明了方法在维持光照和色彩一致性方面的显著优势，建立了一套对不同雾霾环境具有良好鲁棒性的图像去雾算法。

### 5.2 展望

偏振凭借其独有的光学优势在图像去雾领域表现出极大的潜力，其与深度学习的结合为图像去雾提供了全新的可能。本文得到的模型在标准差和平均梯度等性能评估中表现出色，然而受限于时间等因素，课题仍然存在诸多待解决的不足之处：

（1）本课题方法虽然在标准差和平均梯度等指标上表现出色，但是部分场景在亮度表现上仍需进一步优化；

（2）受时间所限，本课题没能在偏振与深度学习的融合方法上做出更多尝试，



当下提出的去雾流程将偏振去雾与无监督学习去雾级联，后续的研究应当探索一种更加深入的结合方式，将偏振去雾的物理原理引入网络当中，起到更强的指导和约束作用；

（3）量化评估指标方面，由于本文进行非配对的去雾，我们难以找到对应的理想数据进行有参考的评价（如 PSNR、SSIM 等指标），而无参考的评估指标不能全面反映去雾前后的提升，有些符合人眼观察习惯的结果在指标上却未必占优。从实验情况来看，平均梯度可以比较准确地反映去雾后图像的清晰度，后续的研究应进一步寻找合适的评估指标。

## 参考文献

- [1] Ancuti C O, Kis A, Ancuti C. Evaluation of image dehazing techniques based on a realistic benchmark[C]//2019 International Symposium ELMAR. IEEE, 2019: 61-64.
- [2] Das B, Ebenezer J P, Mukhopadhyay S. A comparative study of single image fog removal methods[J]. The Visual Computer, 2022, 38(1): 179-195.
- [3] Bi P, Wang D, Chen W, et al. Image dehazing based on polarization information and deep prior learning[J]. Optik, 2022, 267: 169746.
- [4] Guan J, Zhu J. Target detection in turbid medium using polarization-based range-gated technology[J]. Optics express, 2013, 21(12): 14152-14158.
- [5] Liang J, Ren L, Qu E, et al. Method for enhancing visibility of hazy images based on polarimetric imaging[J]. Photonics Research, 2014, 2(1): 38-44.
- [6] Zhang J, Dong Q, Song W. GGADN: Guided generative adversarial dehazing network[J]. Soft Computing, 2023, 27(3): 1731-1741.
- [7] Sakaridis C, Dai D, Van Gool L. Semantic foggy scene understanding with synthetic data[J]. International Journal of Computer Vision, 2018, 126: 973-992.
- [8] Sun C, Kong B, He L, et al. An algorithm of imaging simulation of fog with different visibility[C]//2015 IEEE International Conference on Information and Automation. IEEE, 2015: 1607-1611.
- [9] Schechner Y Y, Narasimhan S G, Nayar S K. Instant dehazing of images using polarization[C]//Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001. IEEE, 2001, 1: I-I.
- [10] Schechner Y Y, Narasimhan S G, Nayar S K. Polarization-based vision through haze[J]. Applied optics, 2003, 42(3): 511-525.
- [11] Liang J, Ren L Y, Ju H J, et al. Visibility enhancement of hazy images based on a universal polarimetric imaging method[J]. Journal of Applied Physics, 2014, 116(17).
- [12] Liang J, Zhang W, Ren L, et al. Polarimetric dehazing method for visibility improvement based on visible and infrared image fusion[J]. Applied optics, 2016, 55(29): 8221-8226.
- [13] Zhang W, Liang J, Ren L. Haze-removal polarimetric imaging schemes with the consideration of airlight's circular polarization effect[J]. Optik, 2019, 182: 1099-1105.
- [14] Hu H, Zhao L, Li X, et al. Polarimetric image recovery in turbid media employing

- circularly polarized light[J]. Optics Express, 2018, 26(19): 25047-25059.
- [15] Li X, Hu H, Zhao L, et al. Polarimetric image recovery method combining histogram stretching for underwater imaging[J]. Scientific reports, 2018, 8(1): 12430.
- [16] Li X, Yan L, Qi P, et al. Polarimetric imaging via deep learning: A review[J]. Remote Sensing, 2023, 15(6): 1540.
- [17] Tan R T. Visibility in bad weather from a single image[C]//2008 IEEE conference on computer vision and pattern recognition. IEEE, 2008: 1-8.
- [18] Fattal R. Single image dehazing[J]. ACM transactions on graphics (TOG), 2008, 27(3): 1-9.
- [19] He K, Sun J, Tang X. Single image haze removal using dark channel prior[J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 33(12): 2341-2353.
- [20] Liu Q. Unsupervised single image dehazing via disentangled representation[C]//Proceedings of the 3rd International Conference on Video and Image Processing. 2019: 106-111.
- [21] Jin Y, Gao G, Liu Q, et al. Unsupervised conditional disentangle network for image dehazing[C]//2020 IEEE International Conference on Image Processing (ICIP). IEEE, 2020: 963-967.
- [22] Yang Y, Wang C, Liu R, et al. Self-augmented unpaired image dehazing via density and depth decomposition[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 2037-2046.
- [23] Narasimhan S G, Nayar S K. Chromatic framework for vision in bad weather[C]//Proceedings IEEE Conference on Computer Vision and Pattern Recognition. CVPR 2000 (Cat. No. PR00662). IEEE, 2000, 1: 598-605.
- [24] Narasimhan S G, Nayar S K. Vision and the atmosphere[J]. International journal of computer vision, 2002, 48: 233-254.
- [25] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.
- [26] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [27] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, pro

- ceedings, part III 18. Springer International Publishing, 2015: 234-241.
- [28] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//International conference on machine learning. PMLR, 2019: 6105-6114.
- [29] Larochelle H, Hinton G E. Learning to combine foveal glimpses with a third-order Boltzmann machine[J]. Advances in neural information processing systems, 2010, 23.
- [30] Mao X, Li Q, Xie H, et al. Least squares generative adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2794-2802.
- [31] Li B, Peng X, Wang Z, et al. Aod-net: All-in-one dehazing network[C]//Proceedings of the IEEE international conference on computer vision. 2017: 4770-4778.

## 致谢

本科四年的学习生涯即将迎来尾声，回想在合肥工业大学度过的时光，一边有逝者如斯的感慨，另一边也切实感受到自己的变化和成长，深深感恩母校为我提供的机会和对我的全面培养。

我非常感激我的毕设指导老师王昕老师。王老师对大家非常负责，开展毕业设计以来总是会定期了解大家的进展，对于我们遇到的问题会设身处地地思考，耐心地分析问题根源和解决方案，循循善诱地引导我们建立起科研思维。我很感谢王老师对我的关心和支持。在毕业设计开题之初，研究生复试的准备工作占据了我很多时间和精力，王老师耐心了解了我们的个人情况，对我们提供了最大程度的理解和支持。王老师的认可和期待我将牢记于心，在今后的研究生学习生涯中以此激励自己不断前进，勇攀科研高峰。

其次我要感谢付伟学长。付伟学长在我进行毕设的过程中为我提供了许多科研上的建议和帮助。从一开始对课题的一无所知，到初见眉目、取得进展，付伟学长始终解答我的疑惑、关心我的进展。我们一起探讨实现课题的可能性，一起开展数据采集工作，用小推车带着设备在校园里拍摄图片将定格为我在合肥工业大学有趣而美好的回忆，毕业论文的写作也得到了学长很大的帮助。祝愿学长在科研上取得新的进展，在未来能够顺利找到心仪的工作岗位。

感谢我可爱的室友。他们是我一路走来最坚实的后盾、最可靠的战友，是我的精神支柱。在开展毕设期间，从互相照顾生活起居到交流科研困惑，室友们为我提供了诸多帮助。回首一起转专业、一起插班补修课程、一起备战考研，一路走来大家互相扶持，感谢有你们一直在。

最后，我要感恩一直给我支持和鼓励的父母。没有来自父母无条件的信任与支持，我不可能来到今天的高度。现在我已不再是大一入学时那个迷茫的孩子，我会走出自己的道路来，用实际行动回馈父母的生养之恩。

作者：项泉智

2024年5月20日